



Elon Musk   @elonmusk · 16小时

Impressive work from Kimi

 282

 264

 3,199

 37.6万 

注意力残差

‘把注意力机制顺时针旋转 90 度’



ATTENTION RESIDUALS

东川路第一可爱猫猫虫

主要内容

- 传统残差连接
- PreNorm Dilution
- Full Attention Residuals
- Block Attention Residuals
- 注意力残差与HC mHC的对比

感谢

创新路西AI的产品经理

迷途小白哟

W0ND3RFULHE4VEN

畜禽哥哥最爱的美娜

阿萨李逍遥张小凡

蕾西亚万岁啊我透

传统残差连接

- 设 $h_l \in \mathbb{R}^d$ 是进入第 l 层的隐状态, f_l 是该层变换
标准残差为

$$h_{l+1} = h_l + f_l(h_l)$$

$$h_l = h_1 + \sum_{i=1}^{l-1} f_i(h_i) = \sum_{i=0}^{l-1} v_i$$

- 过往所有层的输出相加
- 方便梯度回传


$$\frac{\partial \mathcal{L}}{\partial h_l} = \frac{\partial \mathcal{L}}{\partial h_L} \prod_{j=l}^{L-1} \left(I + \frac{\partial f_j}{\partial h_j} \right)$$

传统残差连接的问题

- 是无差别地相加
- 与当前主流模型的其他部分很不对称
- 序列维度上
 - 注意力机制 决定模型更关注哪些token
- 专家维度上
 - MoE router决定每次使用哪些专家
- 唯独模型深度这一维度上还是固定加法

PreNorm Dilution

- $h_{l+1} = h_l + f_l(\text{Norm}(h_l))$
- 每一层残差流都加入增量
每层的相对贡献会越来越小



Full Attention Residuals

- $h_l = h_1 + \sum_{i=1}^{l-1} f_i(h_i) = \sum_{i=0}^{l-1} v_i$

- 改成 $h_l = \sum_{i=0}^{l-1} \alpha_{i \rightarrow l} v_i$

$$\alpha_{i \rightarrow l} = \frac{\exp(w_l^\top \text{RMSNorm}(v_i))}{\sum_{j=0}^{l-1} \exp(w_l^\top \text{RMSNorm}(v_j))}$$

- 每一层都有自己的偏好向量 w_l

第 l 层想要从历史里“找什么类型的信息”

- w_l 不是输入依赖的，不看当前 token

如果用当前 hidden state 生成 query，会再好一点，但会更贵、推理更慢，所以默认不用

模型深度其实就是另一种时间

- $s_t = g(s_{t-1}, x_t)$

RNN到第 t 个时间步只能拿到上一个压缩状态 s_{t-1}

长距离依赖信息难记，信息被压缩稀释

- 解决方法就是注意力机制

不再只依赖 s_{t-1} 这个压缩包，而是直接看所有过去 token

- RNN与attention 传统残差连接与注意力残差

- 传统残差连接的递归 $h_{l+1} = h_l + f_l(h_l)$

全部过去层信息都被压在这个 h_l 里

- layer index l 就像 time step t

HC mHC 注意力残差

- 定义统一的深度混合矩阵 M $h_l = \sum_{i=0}^{l-1} M_{i \rightarrow l} v_i$
- 传统残差连接: $M_{i \rightarrow l} = 1$
- HC与mHC: $H_l = H_{l-1}A_l + f_{l-1}(H_{l-1}\alpha_{l-1})\beta_{l-1}^\top$
- 注意力残差: $M_{i \rightarrow l} = \frac{\exp(w_l^\top \text{RMSNorm}(v_i))}{\sum_{j < l} \exp(w_l^\top \text{RMSNorm}(v_j))}$

直接对所有历史层应用注意力机制

Block Attention Residuals

- 把 L 层分成 N 个 block, 每个 block 内部先用普通加法做局部累加:

$$b_n = \sum_{j \in B_n} f_j(h_j)$$

block 内的前 i 层部分和记为 $b_n^{(i)}$

- block 内仍是递归累加, block 间用注意力检索
- 把 memory / communication 从 $O(Ld)$ 降到 $O(Nd)$
- 实验表明 $N \approx 8$ 已经能拿回大部分收益

HC/mHC 是在把residual stream做复杂
AttnRes 是在把depth变成 attention 轴

