

Shannon's Entropy

Kullback-Leibler Divergence

香农熵 KL 散度

东川路第一可爱猫猫虫



Shannon's Entropy

Kullback-Leibler Divergence

# 香农熵 KL 散度

东川路第一可爱猫猫虫



感谢粉丝大佬  
\_秋山凌\_  
的充电支持

# 主要内容

- 什么是信息
- 如何度量信息
- 惊喜度与香农熵
- 香农熵的代码
- 如何度量两个变量之间的差异
- KL散度（相对熵）
- KL散度的代码实战

# 什么是信息

- 变量

变化的量

有不同取值（不同事件）

在不同时间根据某种过程取多个特定值中的一个

每个取值（事件）有其概率

- 变量是信息的容器

开关

骰子

温度计



- 一个变量可以看作一个存储单元 用来存储信息

# 举个例子

- 图灵机

想象一个双向无限长的一维磁带  
被划分为一个个大小相等的小方格  
每个小方格可以存放一个符号  
每个小方格就构成了一个用来存储信息的存储单元

- 现代计算机

数据的最小存储单位是一个比特  
这个变量取值为0或1  
每个比特的信息就蕴含在它的取值里  
多个比特组合在一起可以表示更复杂的信息

# 我们该如何度量信息

- 文章

如果文章里的内容毫无新意 信息量小

如果文章爆出惊天大猛料 信息量大

- 抽奖 一等奖 二等奖 三等奖

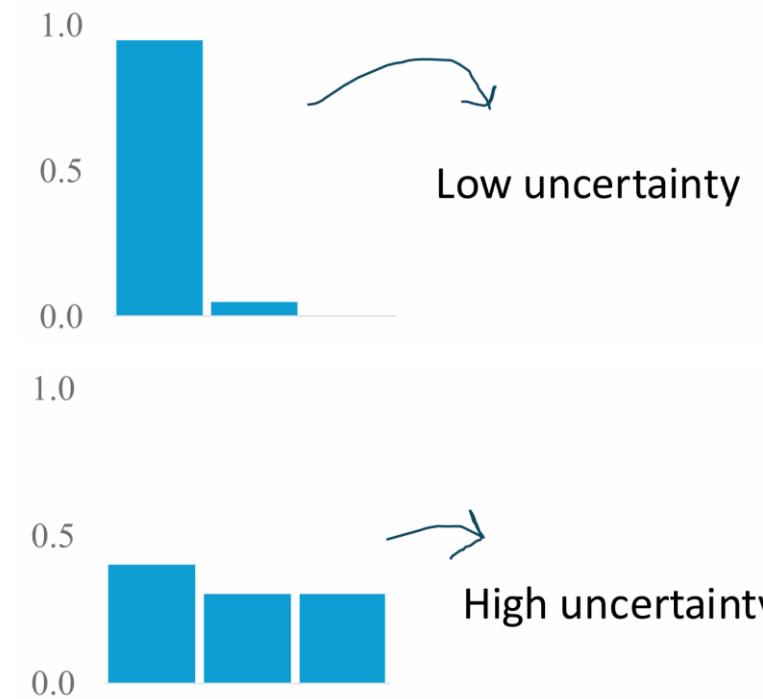
奖池里只有一等奖 毫无惊喜 信息量为0

一等奖概率0.1 二0.2 三0.7 中等惊喜 信息量中等

奖池里一二三等奖概率相同 很难猜中 信息量大

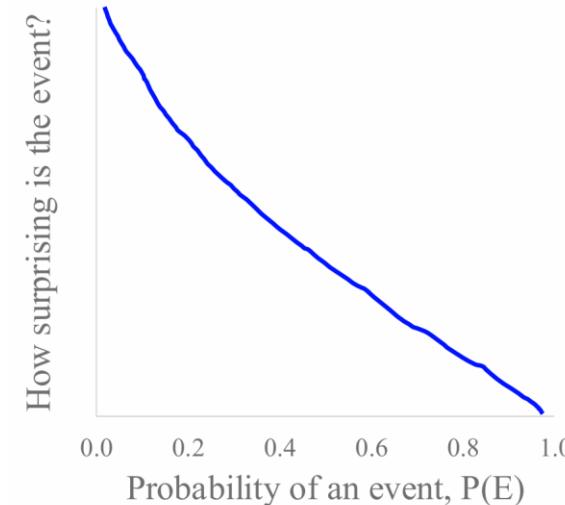
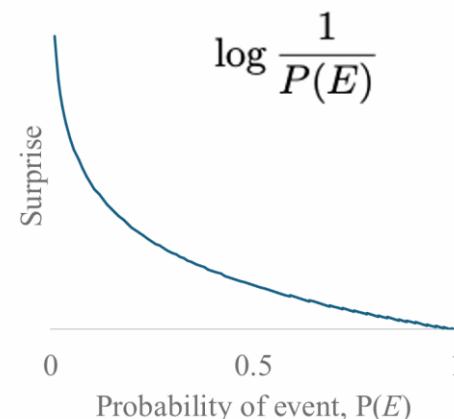
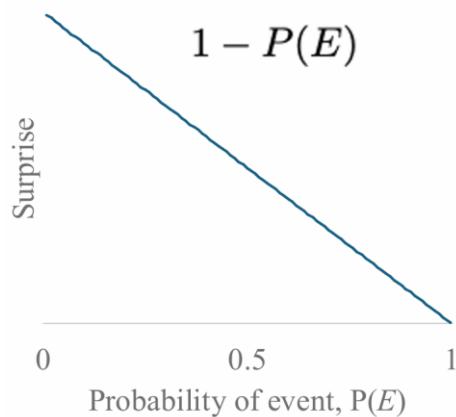
- 信息=惊喜

信息量取决于惊喜度



# 我们该如何度量惊喜度

- 对单个事件而言  
发生概率越低  
惊喜度越高
- 如何量化地定义惊喜度



# 单个事件的惊喜度

- 事件 $x$ 的惊喜度 $I$

$$I(X = x) = \log_2 \frac{1}{P(X=x)}$$

- 为什么选对数?

可加性

两个独立事件的联合惊喜度 = 各自惊喜度之和

概率每减半, 惊喜度+1

- 惊喜度即自信息

self-information

Probability of Event $P(X = x)$	Surprise of Event $I(X = x)$
1	0
$\frac{1}{2}$	1
$\frac{1}{4}$	2
$\frac{1}{8}$	3
$\frac{1}{16}$	4
$\frac{1}{32}$	5
$\frac{1}{64}$	6

# 平均惊喜度

- 我们知道了单个事件 $x$ 的惊喜度

随机变量 $X$ 的平均惊喜度

观测 $X$ 时得到的期望惊喜度

$$\begin{aligned} H(X) &= E(I(X)) = \sum_x \log_2 \frac{1}{P(X=x)} \cdot P(X=x) \\ &= \sum_x -\log_2 P(X=x) \cdot P(X=x) \end{aligned}$$

- $\sum_x -\log_2 P(X=x) \cdot P(X=x)$

“ $H(X)$  Is called Shannon Entropy to scare students and impress Physics people”

$H(X)$ 就是香农熵 **Shannon Entropy**

香农熵直接度量了变量里信息量的大小

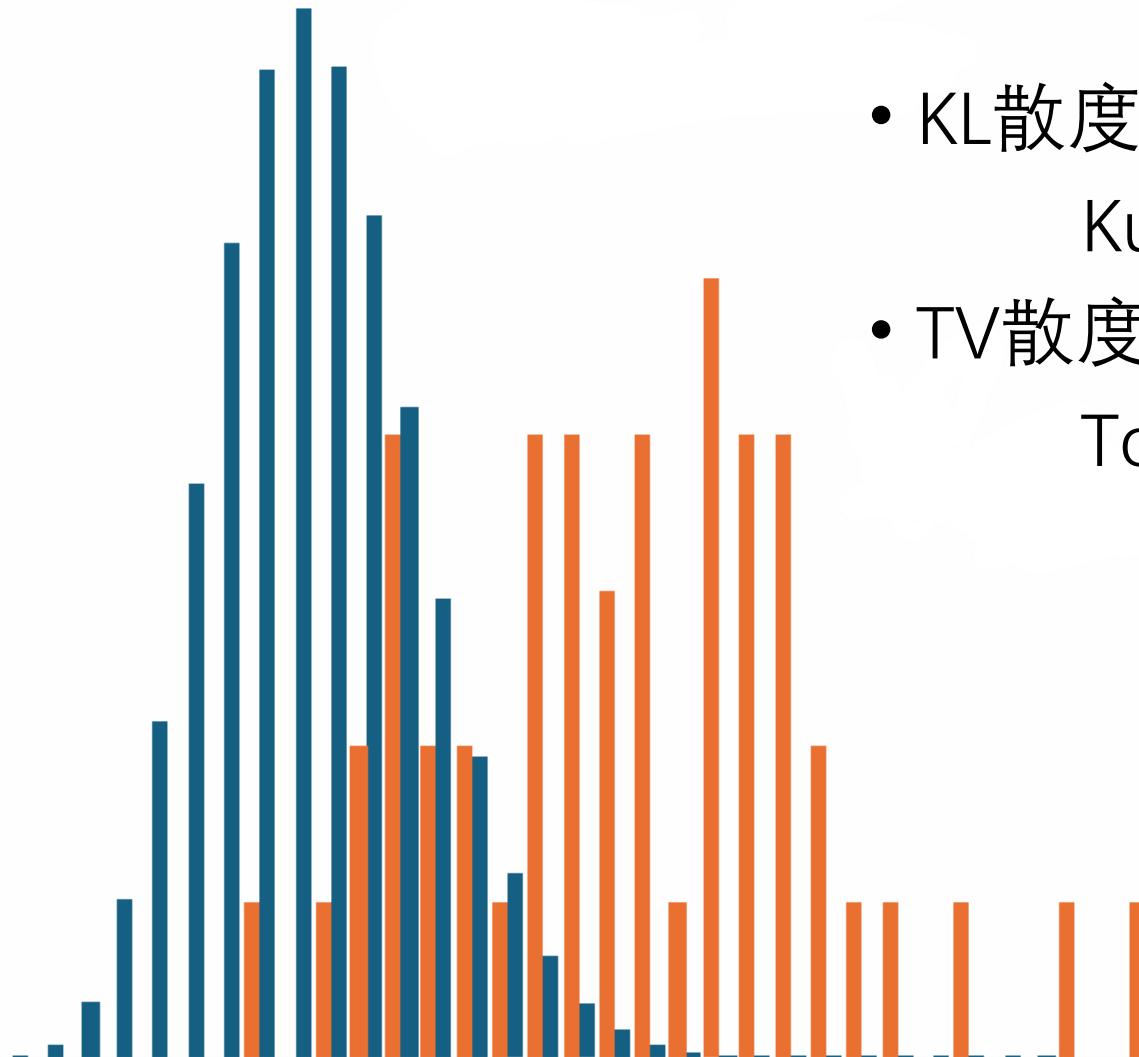
香农熵代表存储一个变量的信息所需的比特数



$$H(X) = \sum_x \log_2 \frac{1}{P(X=x)} \cdot P(X=x)$$

```
def calc_uncertainty(pmf):
    uncertainty = 0
    for x in pmf:
        p_x = pmf[x]
        if p_x == 0:
            continue
        surprise_x = np.log2(1/p_x)
        uncertainty += surprise_x * p_x
    return uncertainty
```

# 我们该如何度量两个变量之间的差异



- KL散度

Kullback Leibler Divergence

- TV散度

Total Variation Distance

# TV散度

- 对两个变量

遍历所有可能的取值

计算绝对差值

再将这些绝对差值求和

$$TV(X, Y) = \sum_i |P(X = i) - P(Y = i)|$$



# KL散度就是期望额外惊喜度

- 当真实分布是 $X$ 时，用 $Y$ 作为模型来近似 $X$ 所带来的期望额外惊喜度
- 期望额外惊喜度

对于事件 $x$ ，在分布 $Y$ 下的期望惊喜度减去在分布 $X$ 下的期望惊喜度

KL 散度是额外惊喜度关于分布 $X$ 取期望

$$\log_2 \frac{1}{P(Y = x)} - \log_2 \frac{1}{P(X = x)}$$

$$KL(X, Y) = \sum_{x \in X} \text{ExcessSurprise}(x) \cdot P(X = x)$$

$$= \sum_{x \in X} \log \frac{P(X = x)}{P(Y = x)} \cdot P(X = x)$$

# KL散度（相对熵）

- 从香农信息论的角度来衡量变量的差异

对于离散随机变量

$$KL(P \parallel Q) = \sum_x P(x) \log \frac{P(x)}{Q(x)}$$

对于连续随机变量

$$KL(P \parallel Q) = \int_{-\infty}^{\infty} p(x) \log \frac{p(x)}{q(x)} dx$$

# 飓风次数预测

- 目标是预测每年发生的飓风次数
- 气象团队提出假设：飓风次数服从泊松分布
$$X \sim \text{Poisson}(\lambda)$$
- 我们需要评估不同 $\lambda$ 值的预测效果
- 解决方案：用KL散度衡量预测分布与观测分布的差异



```
def kl_divergence_poisson(predicted_lambda, observed_pmf,
max_val=None, epsilon=1e-10):
    if max_val is None or max_val > len(observed_pmf):
        max_val = len(observed_pmf)
    X = stats.poisson(predicted_lambda)
    divergence = 0.0
    observed_pmf_smooth = observed_pmf + epsilon
    observed_pmf_smooth = observed_pmf_smooth /
    observed_pmf_smooth.sum()
    for i in range(0, max_val):
        pr_X_i = X.pmf(i)
        pr_Y_i = observed_pmf_smooth[i]
        if pr_X_i == 0:
            continue
        divergence += pr_X_i * np.log(pr_X_i / pr_Y_i)
    return divergence
```

预测lambda=1: KL散度 = 0.8675

预测lambda=2: KL散度 = 0.1745

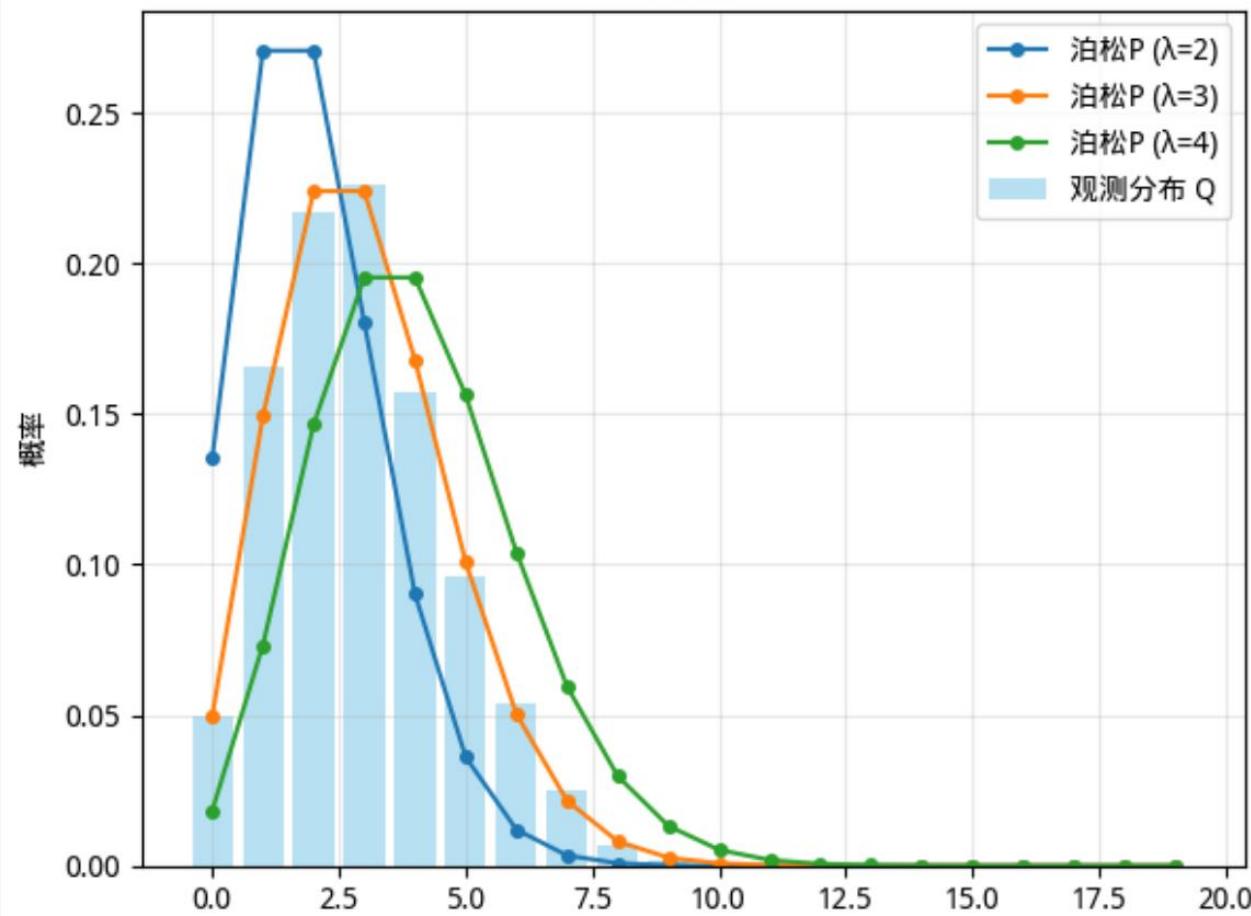
预测lambda=3: KL散度 = 0.0180 <-- 最小值

预测lambda=4: KL散度 = 0.2831

预测lambda=5: KL散度 = 1.0440

预测lambda=6: KL散度 = 2.4092

分布对比



KL散度 vs 预测参数

