

零基础 学透
旋转位置编码RoPE
及其外推方法



三个问题：
我们为什么需要位置编码？
我们为什么需要RoPE？
什么是外推？怎么外推？



我们为什么需要位置编码？

- 传统的词嵌入模型Word2Vec、GloVe
词嵌入向量只包含词义本身，不包含单词位置的信息
- 遇到的问题
他吃早饭 vs 早饭吃他
- 两个句子的词向量集合完全相同（都是“他”“吃”“早饭”的向量），但语义完全相反。而不带Attention Mask的纯Attention模型是全对称的，即天然地满足 $f(x,y)=f(y,x)$
- 如何解决？

我们为什么需要位置编码?

- 绝对位置编码

把词嵌入向量 x_k 与其位置向量 p_k 相加, 其中 p_k 只依赖于位置信息 (位置 k)

$$x_k + p_k$$

- 正余弦位置编码 (Transformer)

$$p_{k,2i} = \sin\left(\frac{k}{10000^{\frac{2i}{d}}}\right), \quad p_{k,2i+1} = \cos\left(\frac{k}{10000^{\frac{2i}{d}}}\right)$$

$p_{k,2i}$ 和 $p_{k,2i+1}$ 是位置 k 的编码向量的第 $2i$ 和第 $2i+1$ 个分量, d 是位置向量的维度, k 表示第几个token (位置)

我们为什么需要RoPE?

- 正余弦位置编码具备一定的表达相对位置的能力
 - token i 的词嵌入向量为 x_i , 位置向量为 $PE(i)$;
 - token j 的词嵌入向量为 x_j , 位置向量为 $PE(j)$
 - attention得分的本质是计算 token i 对 token j 的关注度
 - x_i 与 x_j 做内积, 模型可以但是需要额外“费力”从内积结果中分离出“位置差异”和“语义相关度”

我们为什么需要RoPE?

- 如果不把位置信息**加**到词嵌入向量上，而是**乘**上去
这就是RoPE

给定位置为m的token q_m ，位置为n的token k_n

词嵌入向量与绝对位置信息相乘，得到 $q_m e^{im\theta}$ ， $k_n e^{in\theta}$

这时候我们再来计算一下两个token之间的关注度

$$\begin{aligned} & \langle q_m e^{im\theta}, k_n e^{in\theta} \rangle \\ &= \text{Re}[(q_m e^{im\theta}) (k_n e^{in\theta})^*] \\ &= \text{Re}[q_m k_n^* e^{i(m-n)\theta}] \end{aligned}$$



我们为什么需要RoPE?

- 为什么叫旋转位置编码?

词嵌入向量与绝对位置信息相乘相当于把向量进行旋转

- RoPE的优点:

把相对位置信息显式融入注意力得分
具备外推的潜力



什么是外推？ 怎么外推？

- 外推就是要解决**训练**和**预测**长度不一致的问题
- 两个成因：
 - 预测的时候用到了没训练过的位置编码
 - 预测的时候注意力机制处理的token远超训练时候的
- 一个解决办法：“超强基线模型”
 - 局部attention
 - 掩码，预测时让每个token只能看到训练长度个token
- 实际效果有限
 - 可能的原因：开头的几个token很重要，不能mask掉

什么是外推？ 怎么外推？

- 那还有哪些外推方法呢？

线性缩放（位置内插 Positional Interpolation）

NTK-aware Scaled RoPE

NTK-by-parts

YaRN

Leaky ReRoPE 和 ReRoPE



什么是外推？ 怎么外推？

- 那还有哪些外推方法呢？
- 线性缩放（位置内插 Positional Interpolation）
将超长的位置按比例压缩
压缩了邻近Token的距离，严重扰乱了模型的局部分辨率

- 外推

from 1—1—1—1—1—1—1

to 1——1——1——1——1——1——1——1——1——1

- 内插

from 1—1—1—1—1—1—1

to 1-1-1-1-1-1-1

什么是外推？ 怎么外推？

- NTK-aware Scaled RoPE

低频内插，高频外推 将外推压力平摊到每一个维度

RoPE 中， 维度越高→频率越低→波长越长

训练位置范围： 高频[0 ---- 511]低频 (L_train=512)

推理位置范围： 高频[0 ----- 2047]低频 (L_infer=2048)

- 低频维度的波长极长， 采取内插， 压缩全局位置
- 高频维度的波长极短， 采取外推， 保留局部位位置精细差异

高频1—1—1—1—1—1—1—1—1—1—1低频

高频1—— 1——1-1-1-1-1-1-1-1-1-1-1低频

什么是外推？ 怎么外推？

- NTK-aware Scaled RoPE 存在的问题

波长大于原最大序列长度的那些低频分量，我们对他们进行了外推，会引入一些从未见过的旋转角度，这些旋转角度对应的正余弦值在训练过程中模型也从未见过

- 解决办法

波长大于训练长度（低频）， 就只做内插

波长很短（高频）， 就完全外推

介于中间， 就沿用NTK-aware Scaled RoPE

这就是**NTK-by-parts**



什么是外推？ 怎么外推？

- YaRN Yet another RoPE extension method

YARN: EFFICIENT CONTEXT WINDOW EXTENSION OF LARGE LANGUAGE MODELS

Bowen Peng¹

Jeffrey Quesnelle¹

Honglu Fan²³

Enrico Shippole

¹Nous Research

²EleutherAI

³University of Geneva

YaRN = NTK-by-parts + attention-scaling

attention-scaling就是attention score除以常数t

什么是外推？ 怎么外推？

- Leaky ReRoPE
- 只要 w 选定的是小于训练长度的，那么通过控制 k ，我们就可以在精确保持了局域性的前提下，使得所有位置编码不超过训练长度，简单直接地结合了直接外推和位置内插

$$\left(\begin{array}{cccccccccccc} 0 & & & & & & & & & & \\ 1 & 0 & & & & & & & & & \\ 2 & 1 & 0 & & & & & & & & \\ \ddots & 2 & 1 & 0 & & & & & & & \\ w-1 & \ddots & 2 & 1 & 0 & & & & & & \\ w & w-1 & \ddots & 2 & 1 & 0 & & & & & \\ w+\frac{1}{k} & w & \ddots & \ddots & 2 & 1 & 0 & & & & \\ w+\frac{2}{k} & w+\frac{1}{k} & \ddots & \ddots & \ddots & 2 & 1 & 0 & & & \\ \ddots & w+\frac{2}{k} & \ddots & \ddots & \ddots & \ddots & 2 & 1 & 0 & & \\ \ddots & \ddots & \ddots & \ddots & \ddots & \ddots & \ddots & \ddots & \ddots & \ddots & \\ \ddots & \ddots & \ddots & w+\frac{2}{k} & w+\frac{1}{k} & w & w-1 & \ddots & 2 & 1 & 0 \\ w+\frac{L-1-w}{k} & \ddots & \ddots & \ddots & w+\frac{2}{k} & w+\frac{1}{k} & w & w-1 & \ddots & 2 & 1 & 0 \end{array} \right)$$



什么是外推？ 怎么外推？

- $k \rightarrow \infty$

Leaky ReRoPE

变成ReRoPE

这样，不管输入长度是多少，它的位置编码范围都不超过 w

有可能支持任意长度的Context

[illegible]