

Conjugate Gradient Tutorial

共轭梯度法求解矩阵方程 Fletcher-Reeves方法 Krylov子空间上的迭代

东川路第一可爱猫猫虫



主要内容

感谢粉丝大佬
s7win99
的充电支持

- 求解矩阵方程等价于最小化二次型函数
- Krylov子空间
- 为什么要把Krylov子空间作为解的搜索空间：合理性与必要性
- H 内积与 H 共轭
- 一组两两 H 共轭的向量是线性无关的
- 为什么要用共轭梯度法解矩阵方程
- 步骤

初始化

迭代

终止条件

求解 $Hx=g$

- 共轭梯度法一般用于对称正定的 H
- $H_{n \times n}$
- $g_{n \times 1}$
- 直接求的话
 - n 很大
 - 计算成本和存储成本很高
- 共轭梯度法
 - 把计算量减少到了 H 与列向量的乘积

求解 $Hx=g$ 等价于最小化 $\frac{1}{2}x^T Hx - g^T x$

- 由于 H 对称正定，其二次型 $x^T Hx$ 为凸函数
- $\frac{1}{2}x^T Hx - g^T x$ 也是凸函数，存在最小值
- 最小化 $\frac{1}{2}x^T Hx - g^T x$

要求其梯度

梯度为0处为最小值点

- $\frac{1}{2}x^T Hx - g^T x$ 的梯度为 $Hx-g$
- 求解 $Hx=g$ 实际上是最小化这个二次型函数



Krylov子空间

- Krylov子空间

由一个矩阵和一个向量通过计算生成的线性空间
(H,g)的Krylov子空间 $\mathcal{K}_n(H, g)$ 为

$$\text{span}\{g, Hg, H^2g, \dots, H^{n-1}g\}$$

- 如果能证明解 $x^* = H^{-1}g \in \mathcal{K}_n(H, g)$

那么我们在求解 $Hx=g$ 的时候

可以把Krylov子空间作为解的搜索空间

- 下面我们证明

$$\text{解 } x^* = H^{-1}g \in \mathcal{K}_n(H, g)$$

$$\text{解 } x^* = H^{-1}g \in \mathcal{K}_n(H, g)$$

- Proof

- 由Cayley-Hamilton Theorem

任一方阵一定满足其特征方程

- 假设H的特征方程为 $x^n + a_{n-1}x^{n-1} + \dots + a_0 = 0$

$$\text{则 } H^n + a_{n-1}H^{n-1} + \dots + a_0I = 0$$

$$H^n + a_{n-1}H^{n-1} + \dots + a_1H = -a_0I$$

$$H^{n-1} + a_{n-1}H^{n-2} + \dots + a_1I = -a_0H^{-1}$$

H^{-1} 可以表示为 I, H, \dots, H^{n-1} 的线性组合

$x^* = H^{-1}g$ 可以表示为 $g, Hg, H^2g, \dots, H^{n-1}g$ 的线性组合

- $x^* = H^{-1}g \in \mathcal{K}_n(H, g)$

H共轭性与H内积

- 因此我们将
Krylov子空间作为解的搜索空间
- 自然基 $g, Hg, H^2g, \dots, H^{n-1}g$
可以张成目标搜索空间 $\mathcal{K}_n(H, g)$
但是这组基不满足H共轭性
- H共轭性
由矩阵H诱导的**H内积**下的正交性
- 欧式正交即内积为0
H共轭即H内积为0



H共轭性

- H内积

$$\langle u, v \rangle_H = u^T H v$$

- H共轭

由矩阵H诱导的**H内积**下的正交性

$d_i, d_j (i \neq j)$ 有: $d_i^T H d_j = 0$, 则称 d_i 与 d_j 是H共轭的

- 若一组向量两两H共轭
则这组向量线性无关
- 下面给出证明

若一组向量两两H共轭
则这组向量线性无关

- Proof

- 假设 $\{d_0, d_1, \dots, d_k\}$ 两两H共轭且线性相关

存在不全为0的 $\alpha_0, \dots, \alpha_k$ 使得 $\alpha_0 d_0 + \dots + \alpha_k d_k = 0$

任取 $i \in \{0, 1, 2, \dots, k\}$

$$\alpha_0 d_0^T H d_0 + \dots + \alpha_k d_k^T H d_k = 0$$

由于 $\{d_0, d_1, \dots, d_k\}$ 两两H共轭, 因此 $d_i^T H d_j = 0 \ (i \neq j)$

$$\alpha_i d_i^T H d_i = 0$$

由于H是对称正定阵, 其二次型 $d_i^T H d_i > 0$

因此 $\alpha_i = 0$ 故矛盾

为什么要用共轭梯度法

- 自然基 $g, Hg, H^2g, \dots, H^{n-1}g$ 可以张成目标搜索空间 $\mathcal{K}_n(H, g)$
但他们不是 H 共轭的
- 如果我们可以找到目标搜索空间 $\mathcal{K}_n(H, g)$ 的一组 H 共轭的基
我们就可以就可以把问题解耦到 n 个单一维度
在一个维度上优化不会破坏其他任何维度
只需在每个共轭方向上完成单次优化
即可穷尽该维度的优化空间且不影响其他维度
经过 n 次迭代就可以穷尽 $\mathcal{K}_n(H, g)$
- 共轭梯度法就是在这 n 个 H 共轭的基（搜索方向）上做优化

共轭梯度法的步骤

- 初始化

初始解 x_0

初始残量 $r_0 = g - Hx_0 = -\nabla f(x_0)$

初始化搜索方向 $p_0 = r_0$

- 如何迭代

现有 x_k, r_k, p_k

下一步要找第k步的步长 α_k ，用来求 x_{k+1}, p_{k+1}

计算步长 α_k



- 当前我们要在 p_k 这个搜索方向上求解最小化问题

第 $k+1$ 步迭代的解 $x_{k+1} = x_k + \alpha_k p_k$

最小化 $f(x_{k+1})$

$$f(x_{k+1}) = \frac{1}{2} (x_k + \alpha_k p_k)^T H (x_k + \alpha_k p_k) - g^T (x_k + \alpha_k p_k)$$

$$\frac{\partial f}{\partial \alpha_k} = (x_k + \alpha_k p_k)^T H p_k - g^T p_k = 0$$

$$\text{将残量 } r_k = g - H x_k \text{ 带入 } \frac{\partial f}{\partial \alpha_k} = (x_k + \alpha_k p_k)^T H p_k - g^T p_k = 0$$

$$\alpha_k = \frac{r_k^T r_k}{p_k^T H p_k}$$

一组H共轭的搜索方向

- 我们已经确定了解就在Krylov子空间里
- 所有的迭代目标是高效
- 前提是在n个H共轭的基（搜索方向）上做优化
- 搜索方向同样是一步步迭代出来的
- 新方向由当前残量和上一个方向线性组合而成

$$p_{k+1} = r_{k+1} + \beta_k p_k$$

- 搜索方向的更新公式与 β_k 的计算公式

构成Fletcher-Reeves（简称 FR）公式

新残量 r_{k+1} 与之前所有的搜索方向正交

- Proof
- 先证 $k=0$ 时成立
- $r_1 = g - Hx_1 = g - H(x_0 + \alpha_0 p_0) = g - Hx_0 - \alpha_0 H p_0 = r_0 - \alpha_0 H p_0$
- $r_1^T p_0 = (r_0 - \alpha_0 H p_0)^T p_0 = r_0^T p_0 - \alpha_0 p_0^T H p_0$
$$= r_0^T p_0 - \frac{r_0^T r_0}{p_0^T H p_0} p_0^T H p_0 = 0$$
- 假设 $k=m$ 时命题成立 对所有 $0-m$ 之间的 i 都有 $r_{m+1}^T p_i = 0$
- 要证明 $k=m+1$ 时命题成立 对所有 $0-m+1$ 之间的 i 都有 $r_{m+2}^T p_i = 0$

新残量 r_{k+1} 与之前所有的搜索方向正交

- 目标是证明对所有0-m+1之间的i都有 $r_{m+2}^T p_i = 0$
- 情况一: $0 \leq i \leq m$
- $r_{m+2} = r_{m+1} - \alpha_{m+1} H p_{m+1}$
- $p_i^T r_{m+2} = p_i^T r_{m+1} - \alpha_{m+1} p_i^T H p_{m+1}$
 $= 0$
- 情况二: $i=m+1$
- $p_{m+1}^T r_{m+2} = p_{m+1}^T r_{m+1} - \alpha_{m+1} p_{m+1}^T H p_{m+1}$
- $p_{m+1}^T r_{m+1} = (r_{m+1} + \beta_m p_m)^T r_{m+1} = r_{m+1}^T r_{m+1} + \beta_m p_m^T r_{m+1} = r_{m+1}^T r_{m+1}$
- $\alpha_{m+1} p_{m+1}^T H p_{m+1}$ 带入 $\alpha_k = \frac{r_k^T r_k}{p_k^T H p_k}$ 第二项 $= r_{m+1}^T r_{m+1}$



新残量 r_{k+1} 与之前所有的搜索方向正交

- 至此，我们通过数学归纳法
证明了新残量 r_{k+1} 与之前所有的搜索方向正交
- 由此的一个推论

$$r_{k+1}^T p_i = 0 \text{ 对所有 } i \leq k$$

且 p_k 与 r_k 线性相关

$$\text{可以得到: } r_{k+1}^T r_k = 0$$

残量之间是欧式正交的



搜索方向的迭代更新

- 我们确定了步长 $\alpha_k = \frac{r_k^T r_k}{p_k^T H p_k}$ 和解的更新公式 $x_{k+1} = x_k + \alpha_k p_k$
- 下一步寻找搜索方向的迭代公式
- 要求 p_0, p_1, \dots, p_n 两两的H共轭的
- 现有前k个搜索方向 p_0, p_1, \dots, p_k , 我们要构造 p_{k+1}

新方向由当前残量和上一个方向线性组合而成

$$p_{k+1} = r_{k+1} + \beta_k p_k$$

$$(r_{k+1} + \beta_k p_k)^T H p_k = 0$$

$$r_{k+1}^T H p_k + \beta_k p_k^T H p_k = 0$$

$$r_{k+1}^T H p_k + \beta_k p_k^T H p_k = 0$$

$$\begin{aligned} \bullet \quad r_{k+1} &= g - H x_{k+1} = g - H(x_k + \alpha_k p_k) = g - H x_k - \alpha_k H p_k \\ &= r_k - \alpha_k H p_k \end{aligned}$$

$$\bullet \quad H p_k = \frac{r_k - r_{k+1}}{\alpha_k}$$

$$\bullet \quad \text{将其带入} \quad r_{k+1}^T H p_k = r_{k+1}^T \frac{r_k - r_{k+1}}{\alpha_k}$$

$$r_{k+1}^T H p_k = - \frac{r_{k+1}^T r_{k+1}}{\alpha_k}$$

$$\bullet \quad \beta_k p_k^T H p_k = \frac{r_{k+1}^T r_{k+1}}{\alpha_k} = \frac{r_{k+1}^T r_{k+1}}{\frac{r_k^T r_k}{p_k^T H p_k}}$$

$$\bullet \quad \beta_k = \frac{r_{k+1}^T r_{k+1}}{r_k^T r_k}$$

终止条件

- 残差阈值

残差的内积 rdotr 小于预设阈值

- 最大迭代步数

如果本身矩阵条件够好
只需要一定步数就足够
减少计算成本

