

DAPO: An Open-Source LLM Reinforcement Learning System at Scale

DAPO

Decoupled Clip and Dynamic sAmpling Policy Optimization

东川路第一可爱猫猫虫

主要内容

- Clip-Higher
- Dynamic Sampling
- Token-Level Policy Gradient Loss
- Overlong Reward Shaping
- 移除KL约束

OrcaDude

戾君

迷途小白哟

W0ND3RFULHE4VEN

InterMilan_

Gryffindvenclaw

蕾西亚万岁啊我透

无脚的鸟66

乐冰啊乐冰

OrcaDude

戾君

蜡比大新

MONKEYYY


哈哈h味道

A_sirr

白剽一枚

AELee_

Clip-Higher



- 熵坍塌
- 模型生成各token的概率越接近熵越高
- 低熵意味着模型的输出倾向于单一
这样模型的探索受限
过早得到一个确定性的模型
- 不利于GRPO进行组内比较

Clip-Higher

- $\text{clip}(r_{i,t}(\theta), 1 - \varepsilon, 1 + \varepsilon)$
- DAPO认为这样的裁剪会限制模型的探索
- $\pi_{\theta_{\text{old}}}(o_i | q) = 0.01$ 和 0.9 的两个动作

当 ε 取常见的0.2时

更新后二者的最大概率为 $\pi_{\theta}(o_i | q) = 0.012$ 和 1.08

低概率token的涨幅非常有限

本来概率就高的token所占概率会更高

the stability of RL. We identify that the upper clip can restrict the exploration of the policy. In this case, it is much easier to make an ‘exploitation token’ more probable, than to uplift the probability of an unlikely ‘exploration token’.

Clip-Higher

- DAPO提高clip的上界

如果一个好token的概率极低

那应该允许其概率的提升较为激进

- DAPO把上下裁剪范围解耦为 ϵ_{low} 和 ϵ_{high}

这样为低概率token的概率提升留出更多空间

增加了策略的熵

- 要不要提升 ϵ_{low} ?

提升 ϵ_{low} 的话, 负advantage token的概率可以被压得更低甚至0
会造成sampling space collapse

Dynamic Sampling

- $\hat{A}_{i,t} = \frac{R_i - \text{mean}(\{R_i\}_{i=1}^G)}{\text{std}(\{R_i\}_{i=1}^G)}$
- 如果一个组内的回答全对或全错
就无法形成奖励信号，模型就无法更新
- $0 < |\{o_i \mid \text{is_equivalent}(a, o_i)\}| < G$
 $|\{o_i \mid \text{is_equivalent}(a, o_i)\}|$ 表示G个输出里正确的个数
- DAPO只保留既有正确样本又有错误样本的组
- 动态采样不一定阻碍训练效率

如果 RL 系统是同步的，并且生成阶段没有流水线化，那么生成时间通常由长尾样本主导

Token-Level Policy Gradient Loss

$$\mathcal{J}_{\text{GRPO}}(\theta) = \mathbb{E}_{(q,a) \sim \mathcal{D}, \{o_i\}_{i=1}^G \sim \pi_{\theta_{\text{old}}}(\cdot|q)} \left[\frac{1}{G} \sum_{i=1}^G \frac{1}{|o_i|} \sum_{t=1}^{|o_i|} \left(\min \left(r_{i,t}(\theta) \hat{A}_{i,t}, \text{clip} \left(r_{i,t}(\theta), 1 - \varepsilon, 1 + \varepsilon \right) \hat{A}_{i,t} \right) - \beta D_{\text{KL}}(\pi_{\theta} || \pi_{\text{ref}}) \right) \right]$$

- GRPO先在每个回答内部对各个token取平均
再在组内对各个样本取平均
- 每个样本的权重是相同的，越长的回答里的token的权重越小
- 问题：高质量长样本中的reasoning pattern被低估
- 问题：低质量超长样本惩罚不足
- DAPO按 token 统一归一化 $\frac{1}{\sum_{i=1}^G |o_i|}$

Overlong Reward Shaping

- 超长过滤

截断超长的样本，被截断的样本不参与loss更新

- 软超长惩罚

$$R_{\text{length}}(y) = \begin{cases} 0, & |y| \leq L_{\text{max}} - L_{\text{cache}} \\ \frac{(L_{\text{max}} - L_{\text{cache}}) - |y|}{L_{\text{cache}}}, & L_{\text{max}} - L_{\text{cache}} < |y| \leq L_{\text{max}} \\ -1, & L_{\text{max}} < |y| \end{cases}$$

L_{cache} 表示缓冲区的长度， L_{max} 表示长度上限

- 期望最大长度16384 缓冲区4096

最大可生成长度20480

去掉GRPO目标函数里的KL散度

$$\mathcal{J}_{\text{GRPO}}(\theta) = \mathbb{E}_{(q,a) \sim \mathcal{D}, \{o_i\}_{i=1}^G \sim \pi_{\theta_{\text{old}}}(\cdot|q)} \left[\frac{1}{G} \sum_{i=1}^G \frac{1}{|o_i|} \sum_{t=1}^{|o_i|} \left(\min \left(r_{i,t}(\theta) \hat{A}_{i,t}, \text{clip} \left(r_{i,t}(\theta), 1 - \varepsilon, 1 + \varepsilon \right) \hat{A}_{i,t} \right) - \beta D_{\text{KL}}(\pi_{\theta} || \pi_{\text{ref}}) \right) \right],$$

where

$$r_{i,t}(\theta) = \frac{\pi_{\theta}(o_{i,t} \mid q, o_{i,<t})}{\pi_{\theta_{\text{old}}}(o_{i,t} \mid q, o_{i,<t})}.$$

- DAPO希望训练长 CoT 推理模型
KL散度的限制并非必要