

# GSPO

Group Sequence Policy Optimization

东川路第一可爱猫猫虫

# 主要内容

- GRPO

- on-policy or off-policy

- 为什么需要重要性采样

- GSPO论文认为GRPO存在的问题

- GRPO的重要性权重无法起到分布校正的作用

- reward 的单位和优化的单位不一致

- token之间权重的差异可能会很大

- GRPO训MoE会不稳定 routing replay

# GRPO

$$\mathcal{J}_{\text{GRPO}}(\theta) = \mathbb{E}_{x \sim \mathcal{D}, \{y_i\}_{i=1}^G \sim \pi_{\theta_{\text{old}}}(\cdot|x)} \left[ \frac{1}{G} \sum_{i=1}^G \frac{1}{|y_i|} \sum_{t=1}^{|y_i|} \min \left( w_{i,t}(\theta) \hat{A}_{i,t}, \text{clip}(w_{i,t}(\theta), 1 - \varepsilon, 1 + \varepsilon) \hat{A}_{i,t} \right) \right]$$

- 查询:  $x$       查询集合:  $D$
- 响应:  $y$ , 第  $i$  个响应记为  $y_i$       第  $t$  个 token:  $y_{i,t}$
- 旧策略:  $\pi_{\theta_{\text{old}}}$       每个 query 采样  $G$  个响应
- 重要性权重  $w_{i,t}(\theta) = \frac{\pi_{\theta}(y_{i,t}|x, y_{i,<t})}{\pi_{\theta_{\text{old}}}(y_{i,t}|x, y_{i,<t})}$
- 组内标准化advantage  $\hat{A}_i = \frac{r(x, y_i) - \text{mean}(\{r(x, y_i)\}_{i=1}^G)}{\text{std}(\{r(x, y_i)\}_{i=1}^G)}$
- $\pi_{\theta_{\text{old}}}$  和  $\pi_{\theta}$  具体是什么 为什么需要重要性采样 GRPO是on-policy吗

# 为什么需要重要性采样

- GRPO是on-policy还是off-policy的
  - on policy 训练所用的数据由当前模型本身
  - off policy 训练所用数据来自历史模型或者外部数据
- GRPO可以认为是半on policy
  - 通常会将大批次的rollout数据切分成多个mini-batch来更新
  - $\pi_{\theta_{\text{old}}}$  采样得到rollout数据
  - 每次mini-batch更新时的数据为 $\pi_{\theta}$
- $\pi_{\theta_{\text{old}}}$  和  $\pi_{\theta}$  很接近，但终归不是一个分布，因此不是严格on-policy
  - 因此需要重要性采样来完成分布校正

# 重要性采样

- $\mathbb{E}_{z \sim \pi_{\text{tar}}} [f(z)] = \mathbb{E}_{z \sim \pi_{\text{beh}}} \left[ \frac{\pi_{\text{tar}}(z)}{\pi_{\text{beh}}(z)} f(z) \right]$
- $\pi_{\text{tar}}$  想要优化的目标分布  
对应的就是GRPO的 $\pi_{\theta}$
- $\pi_{\text{beh}}$  实际采样数据来自的行为分布  
对应的就是GRPO的 $\pi_{\theta_{\text{old}}}$
- 用旧policy采样的数据，近似估计当前 policy 下的优化目标  
clip可以防止某些样本太off-policy

# GSPO论文认为GRPO存在问题

- GRPO的重要性权重无法起到分布校正的作用

$$\mathbb{E}_{z \sim \pi_{\text{beh}}} \left[ \frac{\pi_{\text{tar}}(z)}{\pi_{\text{beh}}(z)} f(z) \right]$$

$$\text{GRPO里} \frac{\pi_{\theta}(y_{i,t} | x, y_{i,<t})}{\pi_{\theta_{\text{old}}}(y_{i,t} | x, y_{i,<t})}$$

应该多次采样，但GRPO只能采样一次

- 在 $x, y_{i,<t}$ 的条件下，生成next token的过程只会发生一次  
只采样了 $y_{i,t}$   
相当于把单次采样的结果当成了期望  
因此引入了高方差噪声

# reward 的单位和优化的单位不一致

- 奖励是给整个序列的 seq-level

GRPO 却对每个 token 单独乘一个  $w_{i,t}$ , 再单独做 clip

- PPO 奖励和优化都是token-level的
- GRPO 奖励是seq-level的, 优化是token-level的

GRPO的clip ratio optimization都是token-level的

- GSPO 把奖励和优化统一为seq-level的

The above observation suggests a fundamental issue in GRPO's design. The failure of the token-level importance weight points to a core principle: **the unit of optimization objective should match the unit of reward**. Since the reward is granted to the entire sequence, applying off-policy correction at the token level appears problematic. This motivates us to forego the token-level objective and explore utilizing importance weights and performing optimization directly at the *sequence level*.

# 单位不一致的问题是token权重不同

- $\nabla_{\theta} J_{\text{GRPO}}(\theta) = \mathbb{E} \left[ \frac{1}{G} \sum_{i=1}^G \widehat{A}_i \cdot \frac{1}{|y_i|} \sum_{t=1}^{|y_i|} w_{i,t}(\theta) \nabla_{\theta} \log \pi_{\theta}(y_{i,t} | x, y_{i,<t}) \right]$   
 $w_{i,t}(\theta)$ 是token级别的
- GRPO每个token的重要性权重不同  
每个token根据不同的权重对梯度做加权  
随着训练的进行和序列长度增加而累积token级别的噪声
- token与token之间权重的差异可能会很大  
会进一步放大既有问题

# token与token之间权重的差异可能会很大

- clipping机制

$$\ell_{i,t}(\theta) = \min(r_{i,t}\widehat{A}_i, \text{clip}(r_{i,t}, 1 - \epsilon, 1 + \epsilon)\widehat{A}_i)$$

| <i>advantage</i> 符号 | <i>ratio</i> 区间                         | <i>loss</i> 用哪一项        | 是否有梯度 | 梯度中的 <i>token</i> 权重 |
|---------------------|-----------------------------------------|-------------------------|-------|----------------------|
| $\hat{A} > 0$       | $r < 1 - \epsilon$                      | $r\hat{A}$              | 有     | $r$                  |
| $\hat{A} > 0$       | $1 - \epsilon \leq r \leq 1 + \epsilon$ | $r\hat{A}$              | 有     | $r$                  |
| $\hat{A} > 0$       | $r > 1 + \epsilon$                      | $(1 + \epsilon)\hat{A}$ | 无     | 0                    |
| $\hat{A} < 0$       | $r < 1 - \epsilon$                      | $(1 - \epsilon)\hat{A}$ | 无     | 0                    |
| $\hat{A} < 0$       | $1 - \epsilon \leq r \leq 1 + \epsilon$ | $r\hat{A}$              | 有     | $r$                  |
| $\hat{A} < 0$       | $r > 1 + \epsilon$                      | $r\hat{A}$              | 有     | $r$                  |

# GSPO

- 从token-level ratio改成sequence-level ratio

$$s_i(\theta) = \left( \prod_{t=1}^{|y_i|} w_{i,t}(\theta) \right)^{\frac{1}{|y_i|}}$$

$$s_i(\theta) = \exp \left( \frac{1}{|y_i|} \sum_{t=1}^{|y_i|} \log \frac{\pi_{\theta}(y_{i,t}|x, y_{i,<t})}{\pi_{\theta_{\text{old}}}(y_{i,t}|x, y_{i,<t})} \right)$$

- 长度归一化  $\frac{1}{|y_i|}$


降低方差

减小序列长度对seq-level ratio造成的影响

$$\mathcal{J}_{\text{GSPO}}(\theta) = \mathbb{E}_{x \sim \mathcal{D}, \{y_i\}_{i=1}^G \sim \pi_{\theta_{\text{old}}}(\cdot|x)} \left[ \frac{1}{G} \sum_{i=1}^G \min \left( s_i(\theta) \hat{A}_i, \text{clip}(s_i(\theta), 1 - \varepsilon, 1 + \varepsilon) \hat{A}_i \right) \right]$$

# GRPO训MoE会不稳定

- 在长时间训练后出现不可逆的模型崩溃
- GSPO论文认为MoE这种稀疏激活的结构本身很脆弱  
每次router激活的专家会改变



# routing replay

- 针对GRPO训MoE模型的不稳定  
之前的做法是routing replay路由回放
- 做法  
缓存旧策略  $\pi_{\theta_{old}}$  对每个 token 的 routing, 即激活哪些 experts  
在新策略  $\pi_{\theta}$  里计算 ratio 时, 重放同样的 routing 模式
- 缺点:  
额外的通信和内存开销  
可能限制 MoE 的实际容量利用

# GSPO不再需要routing replay

- $s_i(\theta) = \left( \frac{\pi_{\theta}(y_i|x)}{\pi_{\theta_{\text{old}}}(y_i|x)} \right)^{1/|y_i|}$
- GSPO不需要token级别的ratio保持稳定
- 单个token的局部routing波动不会剧烈影响整个序列
- GSPO不需要Routing Replay, 也能稳定训练