

---

Trust Region Policy Optimization

---

# TRPO 置信域策略优化 第一部

东川路第一可爱猫猫虫



# 主要内容

- TRPO的优势
- 新旧策略期望回报的数值关系
- 折扣访问频率（状态占据度量） $\rho$
- 代理函数与MM算法
- KL散度与TV散度
- Pinsker不等式及其应用
- 从惩罚项到置信域
- 从最大KL散度到平均KL散度
- 基于泰勒展开的近似与海森矩阵

感谢

-泰深满嘴长牙

秋\_0427

两位粉丝大佬的充电

# Trust Region Policy Optimization

- 置信域
  - 旧策略的邻域
- 置信域策略优化
  - 在旧策略的邻域里优化策略
  - 用KL散度来衡量新旧策略的远近，并将其限制在阈值内
- 从理论上证明了单调改进



# 新旧策略的期望回报

- 我们的优化目标

策略 $\pi$ 的期望回报

$$\eta(\pi) = \mathbb{E}_{s_0, a_0, \dots} \left[ \sum_{t=0}^{\infty} \gamma^t r(s_t) \right]$$

- Kakade & Langford, 2002

新策略的期望回报 =

旧策略的期望回报 + 新策略在旧策略优势函数上的累计期望

$$\eta(\tilde{\pi}) = \eta(\pi) + \mathbb{E}_{s_0, a_0, \dots \sim \tilde{\pi}} \left[ \sum_{t=0}^{\infty} \gamma^t A_{\pi}(s_t, a_t) \right]$$

# Discounted visitation frequencies

- 期望具有线性性质

若级数收敛，则求期望和求无穷级数可以交换顺序

$$\mathbb{E}_{s_0, a_0, \dots \sim \tilde{\pi}} [\sum_{t=0}^{\infty} \gamma^t A_{\pi}(s_t, a_t)] = \sum_{t=0}^{\infty} \gamma^t \cdot \mathbb{E}_{s_0, a_0, \dots \sim \tilde{\pi}} [A_{\pi}(s_t, a_t)]$$

- 引入折扣访问频率（状态占据度量）

$$\rho_{\pi}(s) = P(s_0 = s) + \gamma P(s_1 = s) + \gamma^2 P(s_2 = s) + \dots$$

- 表示状态s在策略 $\pi$ 下的长期权重
- 经过t步后处于状态s的折扣概率之和

$$\rho_{\tilde{\pi}}(s) = \sum_{t=0}^{\infty} \gamma^t \cdot \mathbb{P}_{s_0 \sim d, \tilde{\pi}} [s_t = s]$$



# 数学推导

- 将  $A_\pi(s_t, a_t)$  视为随机变量

则它的期望可以分解为：

$$\mathbb{E}_{s_0, a_0, \dots \sim \tilde{\pi}} [A_\pi(s_t, a_t)] = \sum_s \sum_a A_\pi(s, a) \cdot \mathbb{P}_{s_0, a_0, \dots \sim \tilde{\pi}} (s_t = s, a_t = a)$$

- 求和部分的第二项：

$$\mathbb{P}[s_t = s, a_t = a] = \mathbb{P}[s_t = s] \cdot \mathbb{P}[a_t = a \mid s_t = s]$$

- 由于是马尔可夫链，动作选择仅依赖当前状态

$$\mathbb{P}[a_t = a \mid s_t = s] = \tilde{\pi}(a \mid s)$$

$$\mathbb{P}_{s_0, a_0, \dots \sim \tilde{\pi}} (s_t = s, a_t = a) = \mathbb{P}_{s_0, a_0, \dots \sim \tilde{\pi}} (s_t = s) \cdot \tilde{\pi}(a \mid s)$$

$$\mathbb{E}_{s_0, a_0, \dots \sim \tilde{\pi}} [A_\pi(s_t, a_t)] = \sum_s \sum_a A_\pi(s, a) \cdot \mathbb{P}_{s_0, a_0, \dots \sim \tilde{\pi}} (s_t = s) \cdot \tilde{\pi}(a \mid s)$$

# 引入代理函数

$$\mathbb{E}_{s_0, a_0, \dots \sim \tilde{\pi}} \left[ \gamma^t A_{\pi}(s_t, a_t) \right] = \gamma^t \cdot (\sum_s \sum_a A_{\pi}(s, a) \cdot \mathbb{P}(s_t = s) \cdot \tilde{\pi}(a | s))$$

$$\sum_{t=0}^{\infty} \sum_s \sum_a \gamma^t \cdot A_{\pi}(s, a) \cdot \mathbb{P}(s_t = s) \cdot \tilde{\pi}(a | s) = \sum_s \sum_a (\sum_{t=0}^{\infty} \gamma^t \cdot \mathbb{P}(s_t = s)) \cdot \tilde{\pi}(a | s) \cdot A_{\pi}(s, a)$$

$$= \sum_s \rho_{\tilde{\pi}}(s) \sum_a \tilde{\pi}(a | s) A_{\pi}(s, a)$$

$$\eta(\tilde{\pi}) = \eta(\pi) + \sum_s \rho_{\tilde{\pi}}(s) \sum_a \tilde{\pi}(a | s) A_{\pi}(s, a)$$

$$L_{\pi}(\tilde{\pi}) = \eta(\pi) + \sum_s \rho_{\pi}(s) \sum_a \tilde{\pi}(a | s) A_{\pi}(s, a)$$

- 在旧策略 $\pi$ 处， $L_{\pi}$ 和 $\eta$ 的梯度相同

在旧策略附近优化 $L_{\pi}$ ，就近似于优化 $\eta$



# 如何衡量策略的差异

- 两个离散的概率分布p和q
- KL散度

$$D_{KL}(P||Q) = E_p \left[ \log \frac{P(x)}{Q(x)} \right] = \sum_i p_i \log \frac{p_i}{q_i}$$

衡量两个概率分布的远近

表示用q来近似p时的信息损失

- TV散度

$$D_{TV}(P||Q) = \frac{1}{2} \sum_i |p_i - q_i|$$



Pinsker不等式  $\|Q - P\|_{\text{TV}} \leq \sqrt{\frac{1}{2} D_{\text{KL}}(Q \| P)}$

- 由其简化形式得到:

$$D_{\text{TV}}(p || q)^2 \leq D_{\text{KL}}(p || q)$$

- 论文证明了 $L_\pi$ 和 $\eta$ 的误差下界

$$\eta(\pi_{new}) \geq L_{\pi_{old}}(\pi_{new}) - \frac{4\epsilon\gamma}{(1-\gamma)^2}\alpha^2$$

- 其中

$\alpha$ 为新旧两个策略在所有状态下的最大总变差散度

$$\epsilon = \max_{s,a} |A_\pi(s, a)|$$

$$\eta(\tilde{\pi}) \geq L_\pi(\tilde{\pi}) - C \cdot D_{\text{KL}}^{\max}(\pi, \tilde{\pi})$$

$$\eta(\tilde{\pi}) \geq L_{\pi}(\tilde{\pi}) - C \cdot D_{KL}^{\max}(\pi, \tilde{\pi})$$

- 不等式右边成为新策略的性能下界

$$M(\pi) = L_{\pi}(\tilde{\pi}) - C \cdot D_{KL}^{\max}(\pi, \tilde{\pi})$$

- 只要我们提升 $M(\pi)$

或者说：最大化 $M(\pi)$

就能保证 $\eta$ 的性能单调上升

- MM

Minorization-Maximization

每次迭代找到目标函数的一个下界函数

不断求这个下界函数的最大值



# 置信域的引入

- C通常很大

导致惩罚项权重过高

每轮参数更新幅度过小

- 将惩罚项改为置信域

$$\underset{\theta}{\text{maximize}} [L_{\theta_{old}}(\theta) - C \cdot D_{KL}^{\max}(\theta_{old}, \theta)]$$

- 变成：

$$\underset{\theta}{\text{maximize}} \quad L_{\theta_{old}}(\theta)$$

$$\text{subject to} \quad \overline{D}_{KL}^{\rho_{\theta_{old}}}(\theta_{old}, \theta) \leq \delta$$

# 最大KL散度变为平均KL散度

- 最大KL散度

要求所有状态的KL散度都小于某个值  
难以实现

- 平均KL散度

实际上约束的是  
旧策略访问到的状态的平均KL散度

$$\overline{D}_{\text{KL}}^{\rho}(\theta_1, \theta_2) := \mathbb{E}_{s \sim \rho} [D_{\text{KL}}(\pi_{\theta_1}(\cdot | s) \parallel \pi_{\theta_2}(\cdot | s))]$$

# 重要性采样

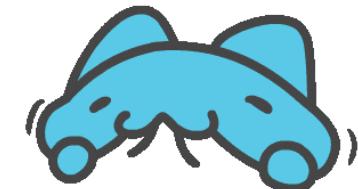
- 我们想计算  $E_{X \sim q}[f(X)]$

从  $q$  上采样，可能不是最优的

$$\begin{aligned} \mathbb{E}_{X \sim q}[f(X)] &= \int f(x)q(x)dx \\ &= \int f(x) \cdot \frac{q(x)}{p(x)} \cdot p(x)dx \\ &= \mathbb{E}_{X \sim p} \left[ f(X) \cdot \frac{q(x)}{p(x)} \right] \end{aligned}$$

- $\frac{q(x)}{p(x)}$  称为重要性权重

从  $p(x)$  采样的样本修正到  $q(x)$  分布下的期望估计



# 重要性采样

$$\underset{\theta}{\text{maximize}} \quad L_{\theta_{old}}(\theta)$$

$$L_{\theta_{old}}(\theta) = \mathbb{E}_{s \sim \rho_{\theta_{old}}, a \sim \pi_{\theta}} [A_{\pi_{\theta_{old}}}(s, a)]$$

$$\text{subject to} \quad \overline{D}_{KL}^{\rho_{\theta_{old}}}(\theta_{old}, \theta) \leq \delta$$

- $L_{\theta_{old}}(\theta)$ 指的是新策略 $\theta$ 相比于旧策略 $\theta_{old}$ 的性能改进期望

这里的 $a$ 需要从新策略 $\theta$ 里采样动作

可我们只能从旧策略 $\theta_{old}$ 里采样动作

因此使用重要性采样：

$$\mathbb{E}_{a \sim \pi_{\theta}} [f(a)] = \mathbb{E}_{a \sim \pi_{\theta_{old}}} \left[ f(a) \cdot \frac{\pi_{\theta}(a|s)}{\pi_{\theta_{old}}(a|s)} \right]$$

$$L_{\theta_{old}}(\theta) = \mathbb{E}_{s \sim \rho_{\theta_{old}}, a \sim \pi_{\theta_{old}}} \left[ \frac{\pi_{\theta}(a|s)}{\pi_{\theta_{old}}(a|s)} \cdot A_{\pi_{\theta_{old}}}(s, a) \right]$$

# 近似

- TRPO在 $\theta = \theta_{old}$ 附近做近似:
- 目标函数L与约束条件

目标函数 $L_{\theta_{old}}(\theta)$  在 $\theta = \theta_{old}$ 做一阶泰勒展开

约束条件 (平均KL散度) 在 $\theta = \theta_{old}$ 做二阶泰勒展开

$$L_{\theta_{old}}(\theta) \approx L_{\theta_{old}}(\theta_{old}) + \nabla_{\theta} L_{\theta_{old}}(\theta_{old}) \cdot (\theta - \theta_{old})$$

$$\overline{D}_{KL}(\theta_{old}, \theta_{old}) - \nabla_{\theta} \overline{D}_{KL}(\theta_{old}, \theta) \Big|_{\theta=\theta_{old}}$$

$$\overline{D}_{KL}^{\rho_{\theta_{old}}}(\theta_{old}, \theta) \approx \frac{1}{2} \Delta \theta^T A \Delta \theta$$

- 这里的 $\Delta \theta$ 为参数的更新量

A为平均KL散度在 $\theta_{old}$ 处的Hessian矩阵

# 海森矩阵

- 海森矩阵

多元函数二阶偏导数构成的对称矩阵

$f(X)$ 在 $X(0)$ 处的海森矩阵为

$$\begin{bmatrix} \frac{\partial^2 f}{\partial x_1^2} & \frac{\partial^2 f}{\partial x_1 \partial x_2} & \cdots & \frac{\partial^2 f}{\partial x_1 \partial x_n} \\ \frac{\partial^2 f}{\partial x_2 \partial x_1} & \frac{\partial^2 f}{\partial x_2^2} & \cdots & \frac{\partial^2 f}{\partial x_2 \partial x_n} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial^2 f}{\partial x_n \partial x_1} & \frac{\partial^2 f}{\partial x_n \partial x_2} & \cdots & \frac{\partial^2 f}{\partial x_n^2} \end{bmatrix}_{X^{(0)}}$$

- A就是

$$\frac{\partial}{\partial \theta_i} \frac{\partial}{\partial \theta_j} \mathbb{E}_{s \sim \rho_\pi} [D_{\text{KL}}(\pi(\cdot|s, \theta_{\text{old}}) \parallel \pi(\cdot|s, \theta))] \Big|_{\theta=\theta_{\text{old}}}$$

问题转化为

$$\max g^T(\theta - \theta_{old})$$

$$s.t. \frac{1}{2}(\theta - \theta_{old})^T H(\theta - \theta_{old}) \leq \delta$$

- $g$ 就是刚才的 $\nabla_{\theta} L_{\theta_{old}}(\theta_{old})$
- $H$ 就是刚才的海森矩阵